

LEC1
Estadística Computacional 2015-1, UTFSM

Gonzalo Moya 201173016-k

Valparaíso, 30 de Octubre del 2015

Contents

1	Introducción	3
2	Desarrollo	3
2.1	Pregunta 1	3
2.2	Pregunta 2	3
2.3	Pregunta 3	6
2.4	Pregunta 4	8
2.5	Pregunta 5	9
2.6	Pregunta 6	10
2.7	Pregunta 7	10
2.8	Pregunta 8	10
3	Conclusiones	10
4	Anexos	10

1 Introducción

2 Desarrollo

2.1 Pregunta 1

Para estudiar la dispersión de las variables se construye una tabla con la desviación estandar (S), la media (X) y el coeficiente de variación (C_v).

Variable	S	X	C_v
mpg	7.815984	23.51457	0.332389
cylinders	1.701004	5.454774	0.3118377
displacement	104.2698	193.4259	0.5390687
horsepower	38.26078	104.2638	0.3669613
weight	846.8418	2970.425	0.2850912
acceleration	2.757689	15.56809	0.1771373
model year	3.697627	76.01005	0.04864655
origin	0.8020549	1.572864	0.5099327

Si bien se podría analizar la varianza o la desviación estándar para cada variable esto haría mas engorroso el estudio ya que todas las variables no estan en medidas similares por lo que comparar el valor de una con la otra directamente no nos permite discriminar cual variable podría ser mas exacta. Para contrarrestar lo anterior se utiliza el coeficiente de variación el cual a través de la división entre la desviación estándar y la norma permite entregar valores que se mueven entre 0 y 1, los que además se encuentran normalizados por las medias de cada variable que se preocupa de hacer el ajuste para el análisis de variables con valores tan distintos como es el presente caso. Una vez encontrados todos los coeficientes de variación se debe analizar los valores más cercanos a 0. Entre ellos la más homogénea termina siendo el año de los modelos, lo cual se podía sospechar a simple inspección de la data a través del sumario de cada variable ya que el año del modelo se mueve entre 70 y 82 a diferencia de otras que tienen grandes valores dentro de sus dominios.

2.2 Pregunta 2

Para analizar este punto es necesario ver como se ha comportado la cantidad de autos a través del tiempo, en este ámbito lo mejor que podemos hacer es utilizar un histograma.

Observando el gráfico es posible notar que entre los años 70 y 78 existe cierta irregularidad en la cantidad de modelos por año, logrando la estabilidad desde el 78 en adelante. Las razones que puedan explicar esto son múltiples por ejemplo en aquellos años no existía la renovación del vehículo por parte de cada dueño cada 1 o 2 años como ocurre hoy en día, además en los años 70 aún era un mercado emergente que no permitía proyectar bien la demanda.




Figure 1: lala




Figure 2: This is the first figure




Figure 3: This is the second figure

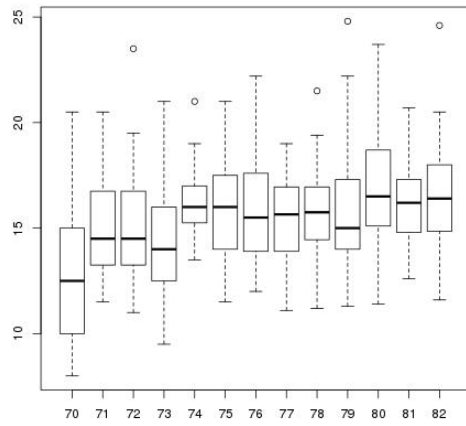


Figure 4: This is the first figure




Figure 5: This is the second figure

2.3 Pregunta 3

Intuitivamente se puede creer que una cilindrada alta implicaría un mayor número de cilindros en el motor, pero eso no es suficiente para el análisis por lo que es necesario realizar boxplots donde en un eje se encuentren la cilindrada y en otro la cantidad de cilindros con el fin de partir el conjunto de cilindrada en grupos por cilindro ilustrados por los diagramas. A primera vista es posible observar




Figure 6: lala

que a medida que se aumentan los cilindros es posible encontrar motores con mayor cilindradas. La mayoría de las cajas se encuentran acopladas solo por los bigotes lo que muestra que existe una posible separación entre cada grupo de cilindros y la cilindrada posible pero es importante destacar que esto no es una separación estricta sino que solamente la concentración de los datos entre cada grupo se encuentra distante donde los bigotes permiten realizar la “unión” entre el conjunto de datos de cada boxplot lo cual indica que estos serían una cantidad mínima de datos en relación a las cajas en si. Otro elemento importante es que se puede observar una relación lineal con pendiente positiva entre los boxplot pero la simple inspección no es suficiente por lo que se calculará la covarianza entre estas dos variables. La covarianza es 168.6232, al ser positiva implica una relación proporcional entre ambas variables por lo que las observaciones a partir de los boxplot coinciden hasta cierto punto, pero la covarianza no nos entrega la intensidad de la relación por lo que se realiza el cálculo de otra herramienta disponible hasta el momento, la cual es la correlación lineal, con un valor de 0.9507214 positiva y muy cercana a 1 implica una intensidad fuerte en la proporcionalidad entre los cilindros y la cilindrada de los modelos. Nuevamente la mayor parte de los boxplot no están desacoplados por lo que se puede percibir una relación entre ellos, a primera vista se puede pensar que la relación será relativamente parecida a la anterior pero si se toma atención especial en los boxplot se pueden descubrir elementos que no dejarán desarrollar una hipótesis similar a la anterior. A diferencia del caso anterior aquí se presenta una disminución en los valores de la potencia para las menores cantidades de cilindros. Aparecen 2 datos atípicos, uno en la cantidad de cilindros 6 y otra en 8, donde ambos outliers son en valores muy altos en relación al resto que se encuentra dentro de sus boxplot respectivos. Existen 2 boxplot que tienen bigotes “largos” mientras que el resto los tienen muy cortos en relación a su tamaño lo que da para pensar que existe poca dispersión en cada caso, a esto hay que agregar que la mayoría de los boxplot tienen la concentración de los datos entre su primer cuartil y su mediana es decir que la mayor parte se encuentra en los valores menores dentro de su espectro de valores posibles, además




Figure 7: lala

todas las medianas a excepción de la que corresponde a 8 cilindros, se encuentran en un valor cercano o menor a 100. El único que no lo cumple a su vez, resulta ser el boxplot que demuestra la mayor dispersión de los datos, nuevamente nos referimos a la cantidad de 8 cilindros, esto a priori permite imaginar que la dispersión de sus valores no alcanza a hacer el correspondiente peso sobre el resto de los boxplot con fuertes concentraciones en aceleraciones bajo los 100. Para acompañar la argumentación anterior se calcula la covarianza, esta es de -2.370842 , al ser negativa entonces implica una relación inversamente proporcional reafirmando gran parte de lo dicho anteriormente pero es necesario conocer su intensidad, por lo que se utilizará la correlación lineal, siendo -0.5054195 . Al encontrarse entre -1 y 0 no es tan fácil afirmar que tan fuerte es la intensidad de la relación. Tal vez otro indicador que no busque ajustar mediante alguna recta los datos nos podría entregar una relación más precisa.

2.4 Pregunta 4

Del resumen de los datos se desprende que el tercer cuartil es 125, y que el valor máximo es 238, por lo que los boxplot que muestren valores entre estos dos números podrán asegurar tener las potencias más altas.




Figure 8: lala

En este grupo se encuentran todos, pero si no contamos los bigotes entonces se consideran los años entre el 70 y el 79 como los con mayores potencias, la primera idea al respecto es que la modernización tanto de la construcción de vehículo como de la eficiencia de los motores puede permitir que a través de los años se requiera menos potencia para que estos puedan moverse adecuadamente. Pero de este gran conjunto de años algunos presentan datos atípicos, estos son el 74, 75 y 77 además desde el 74 en adelante existe mucha diferencia entre los valores que alcanzan las cajas sin contar los bigotes respecto los que se encuentran en el 70-73, por lo que quedan descartados los del 74 en adelante. Ahora el grupo en cuestion está entre el 70 y el 73, pero si se observan detenidamente es posible ver que existen dos grupos uno con mayor potencia que el otro, notando que la diferencia entre sus medianas es alta sumado a que los del 71 y 72 concentran la mayor parte de sus datos en valores mucho menores que los del 70 y 73. Finalmente se concluye que el rango de años con mayor potencia es el 70-73 pero los años con modelos de mayor potencia son específicamente el 70 y el 73.

2.5 Pregunta 5

Para encontrar este grupo, se decide particionar el consumo en base al origen, luego se realizan boxplot de cada nuevo grupo permitiendo observar relaciones directas entre origen y el consumo que hay según este. A primera vista se descarta el boxplot que corresponde a los modelos de origen 3, ya que este




Figure 9: lala

presenta una concentración de datos en valores mayores a 30, lo que supera fácilmente a los de origen 1 y 2. De los restantes se observa que el los que corresponden al origen 1 poseen menor consumo que los del grupo 2, sin ahondar mucho, el largo de los bigotes de la caja 2 puede hacer pensar que podría llegar a ponderar menos consumo ayudado de su concentración de datos en sus valores menores, pero para ello necesitaría que la caja estuviera menos desacoplada respecto a la primera, ya que cuando termina una empieza la otra, dejando a la del grupo de origen 2 sin oportunidad. Por lo tanto los vehículo correspondientes al origen 1 son los de menor consumo.

2.6 Pregunta 6

Para encontrar la respuesta es necesario realizar una partición de la aceleración y de la potencia, ambas respecto al origen, luego graficar los resultados mediante boxplots tomando en consideración los que corresponden al origen 1.





Figure 10: This is the first figure

Figure 11: This is the second figure

De ambos, se puede notar que tanto como en aceleración como en potencia los vehículos de origen 1 abarcan casi la totalidad de los valores posibles en la muestra, lo que podría dificultar el análisis. Pero para resolver esto se debe observar que el que corresponde a la potencia posee una concentración de sus datos sus valores menores pero sus cuartiles abarcan datos altos y bajos. Para hacer un análisis más preciso se obtienen la covarianza, la cual es de -78.31126 , de esto se entiende que existe una relación inversamente proporcional, pero se requiere de otro indicador para encontrar la intensidad de esta relación, para ello se usa el coeficiente de correlación lineal, que retorna un valor de -0.7160874 , al ser negativo pero más cercano al -1 que al 0 entonces es posible concluir que la relación es lineal inversamente proporcional.

2.7 Pregunta 7

2.8 Pregunta 8

3 Conclusiones

4 Anexos

References

- [1] Nombre de la referencia, Autor.